tidyr

Entornos de Análisis de Datos: R

Alberto Torres Barrán

2021-01-07

Introducción

- El 80% del tiempo de un análisis se emplea limpiando y preparando los datos (Dasu y Johnson, 2003)
- Importados los datos, es importante estructurarlos para que el análisis sea lo más fácil posible
- Las librerías del tidyverse están construidas alrededor del concepto de datos ordenados o *tidy data*:
    1. Cada variable forma una columna
    2. Cada observación forma una fila
    3. Cada celda contiene un único valor
- Todas las librerías del tidyverse están construidas alrededor de este concepto
- Datos tabulares/rectangulares no implican datos ordenados!!!

Formas de almacenamiento

Distintas formas de almacenar los mismos datos [R for Data Science]:

country	1999	2000
Afghanistan	745	2666
Brazil	37737	80488
China	212258	213766

country	year	cases
Afghanistan	1999	745
Afghanistan	2000	2666
Brazil	1999	37737
Brazil	2000	80488
China	1999	212258
China	2000	213766

Formatos "ancho" y "largo"

wide

id	x	y	z
1	a	c	e
2	b	d	f

long

id	key	val
1	x	a
2	x	b
1	y	c
2	y	d
1	z	e
2	z	f

Fuente: https://github.com/gadenbuie/tidyexplain

Operaciones con datos ordenados

- Tabla 1

country	year	cases	population
Afghanistan	1999	745	19987071
Afghanistan	2000	2666	20595360
Brazil	1999	37737	172006362
Brazil	2000	80488	174504898
China	1999	212258	1272915272
China	2000	213766	1280428583

- Tabla 2

country	cases_1999	cases_2000	population_1999	population_2000
Afghanistan	745	2666	19987071	20595360
Brazil	37737	80488	172006362	174504898
China	212258	213766	1272915272	1280428583

Crear una nueva variable

- Crear una nueva variable es fácil con la tabla 1

```
table_1 %>%
  mutate(ratio = cases / population * 10000)
## # A tibble: 6 x 5
##   country      year  cases population ratio
##   <chr>       <int>  <int>      <int> <dbl>
## 1 Afghanistan  1999    745   19987071 0.373
## 2 Afghanistan  2000   2666   20595360 1.29
## 3 Brazil       1999  37737  172006362 2.19
## 4 Brazil       2000  80488  174504898 4.61
## 5 China        1999 212258 1272915272 1.67
## 6 China        2000 213766 1280428583 1.67
```

- ¿Como podríamos hacer lo mismo con la tabla 2?

Operaciones agrupadas

- Tabla 1: calcular el total de casos por año

```
table_1 %>%
  group_by(year) %>%
  summarize(total = sum(cases))
## # A tibble: 2 x 2
##    year  total
##   <int>  <int>
## 1  1999 250740
## 2  2000 296920
```

- Tabla 2: el resultado final está en un formato que es más dificil de procesar

```
table_2 %>%
  summarize(across(starts_with("cases"), sum))
## # A tibble: 1 x 2
##   cases_1999 cases_2000
##        <int>      <int>
## 1     250740     296920
```

Gráficos

```
table_1 %>%
  mutate(ratio = cases / population * 10000,
         year = as.character(year)) %>%
  ggplot(mapping = aes(x = country, y = ratio, fill = year)) +
    geom_col(position = "dodge")
```

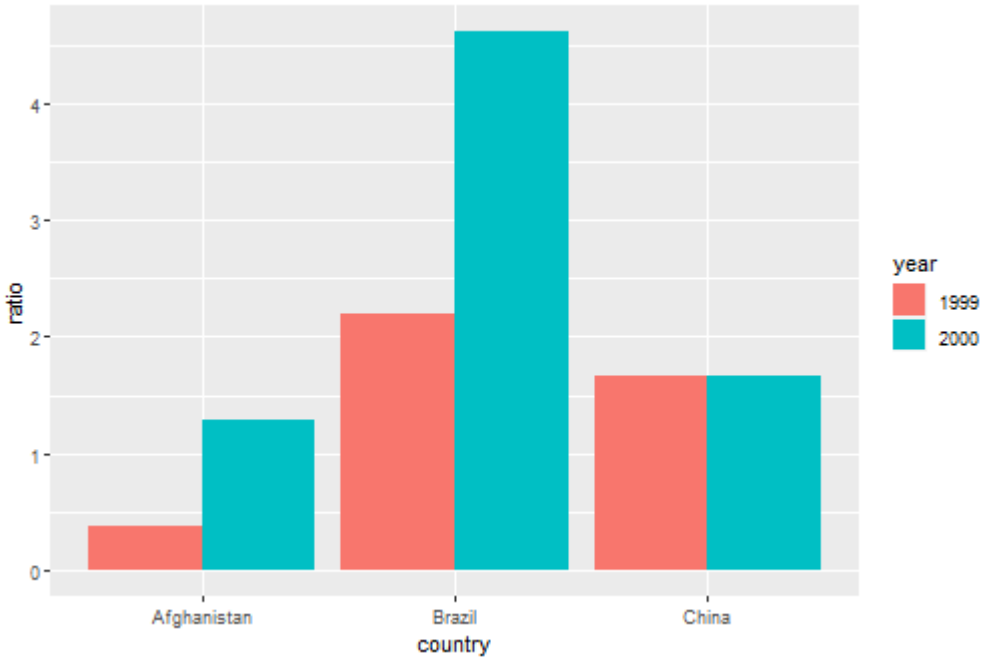

Librería tidyr

- Implementa funciones para transformar entre los formatos anteriores
- Desde la versión 1.0 de tidyr, se han creado versiones más potentes de las antiguas `spread` y `gather`
- En la siguiente tabla podemos ver la equivalencia:

pandas	tidyr <1.0	tidyr 1.0	data.table	reshape2
pivot	spread	pivot_wider	dcast	cast
melt	gather	pivot_longer	melt	melt

pivot_longer

- Pivota una dataframe para que cada variable tenga su propia columna (documentación)

```
table4a
## # A tibble: 3 x 3
##   country     `1999` `2000`
## * <chr>        <int>  <int>
## 1 Afghanistan    745   2666
## 2 Brazil       37737  80488
## 3 China       212258 213766
```

```
pivot_longer(table4a, names_to = "year", values_to = "cases", -country)
## # A tibble: 6 x 3
##   country     year   cases
##   <chr>       <chr>  <int>
## 1 Afghanistan 1999     745
## 2 Afghanistan 2000    2666
## 3 Brazil      1999   37737
## 4 Brazil      2000   80488
## 5 China       1999  212258
## 6 China       2000  213766
```

Animación

resp_id	age	airplane	anchorman	bridesmaids
1	48	TRUE	TRUE	TRUE
2	31	FALSE	TRUE	TRUE
3	30	FALSE	FALSE	FALSE

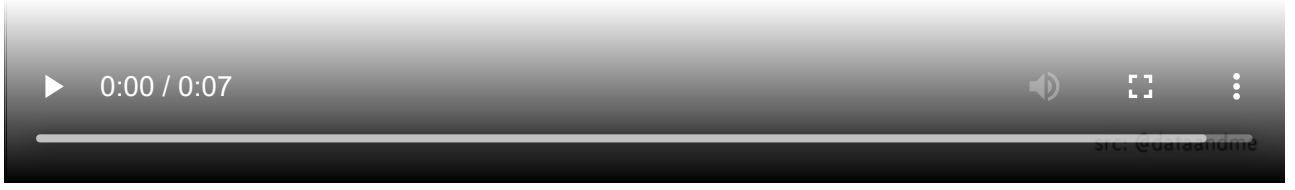

Ejemplo pivot_longer

- Queremos representar las siguientes series temporales, que representan 4 indicadores económicos:

```
eu <- EuStockMarkets %>%
  data.frame() %>%
  mutate(index = 1:n())
head(eu)
##       DAX    SMI    CAC   FTSE index
## 1 1628.75 1678.1 1772.8 2443.6     1
## 2 1613.63 1688.5 1750.5 2460.2     2
## 3 1606.51 1678.6 1718.0 2448.2     3
## 4 1621.04 1684.1 1708.1 2470.4     4
## 5 1618.16 1686.6 1723.1 2484.7     5
## 6 1610.61 1671.6 1714.3 2466.8     6
```

- Las 4 variables tienen las mismas unidades, por lo que podemos representar 4 líneas en un único gráfico:

```
ggplot(eu, aes(x = index)) +
  geom_line(aes(y = DAX), color = "red") +
  geom_line(aes(y = SMI), color = "blue") +
  geom_line(aes(y = CAC), color = "green") +
  geom_line(aes(y = FTSE), color = "orange")
```

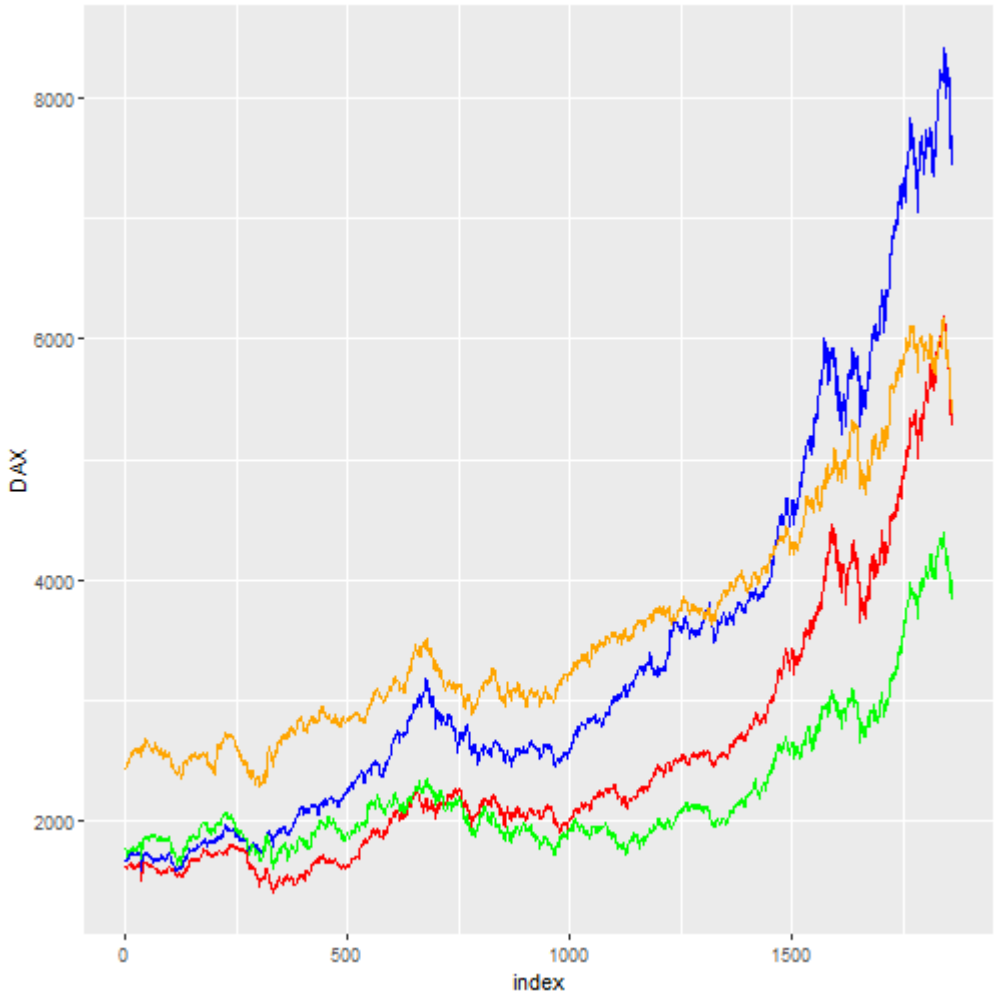
8000
6000
4000
2000
DAX
0
500
1000
1500
index

- Pivotamos a formato "largo"

```
eu_long <-
  eu %>%
    pivot_longer(-index, names_to = "name", values_to = "value")

head(eu_long, 8)
## # A tibble: 8 x 3
##   index name  value
##   <int> <chr> <dbl>
## 1     1 DAX   1629.
## 2     1 SMI   1678.
## 3     1 CAC   1773.
## 4     1 FTSE  2444.
## 5     2 DAX   1614.
## 6     2 SMI   1688.
## 7     2 CAC   1750.
## 8     2 FTSE  2460.
```

- Repetimos el gráfico anterior, asignando el nombre del indicador a la propiedad `color`

```
ggplot(eu_long, aes(x = index, y = value, color = name)) +
  geom_line()
```

- Ventajas:

  1. código más conciso
  2. colores elegidos de forma automática a partir de una paleta
  3. leyenda automática

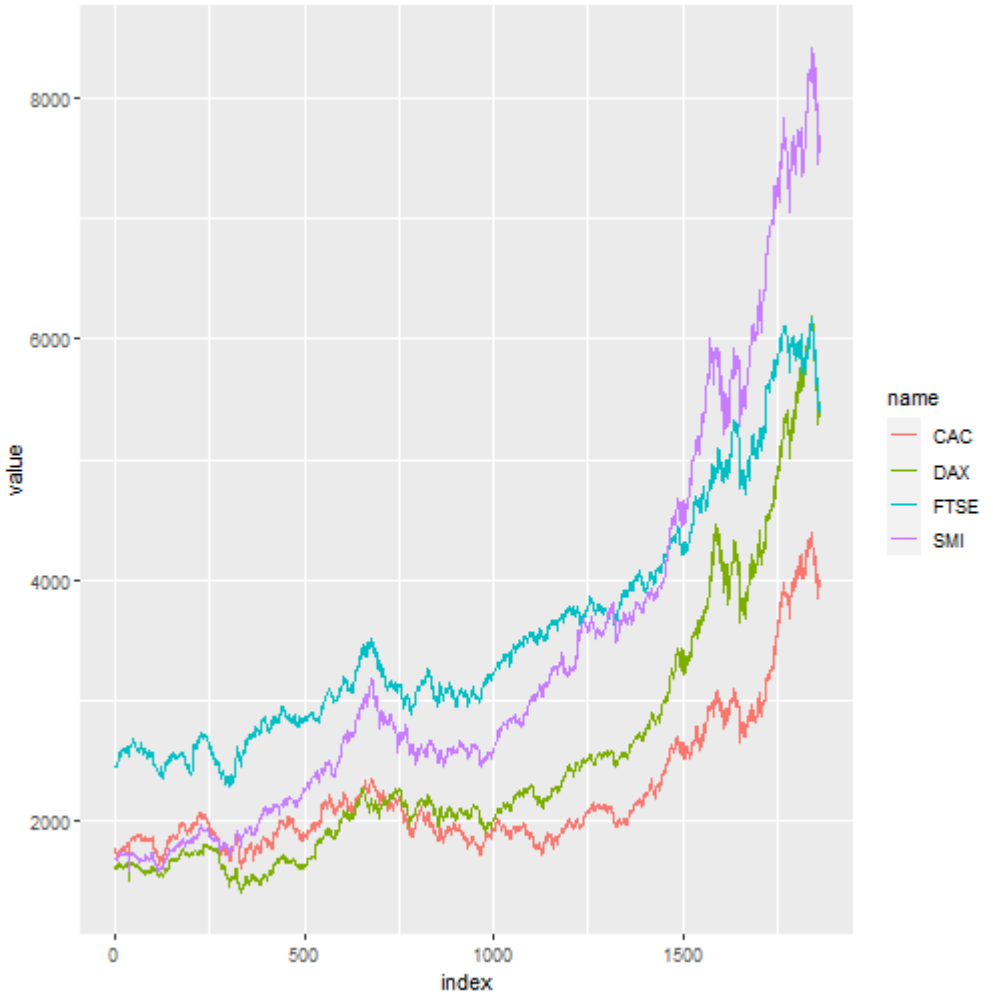
8000
6000
4000
2000
value
0
500
1000
1500
index
name
CAC
DAX
FTSE
SMI

Ejemplo avanzado

```
stats <-
  mpg %>%
    summarize(across(is.numeric, list(mean = mean, sd = sd)))

stats
## # A tibble: 1 x 10
##   displ_mean displ_sd year_mean year_sd cyl_mean cyl_sd cty_mean cty_sd hwy_mea
##        <dbl>    <dbl>     <dbl>   <dbl>    <dbl>  <dbl>    <dbl>  <dbl>    <dbl
## 1       3.47     1.29     2004.    4.51     5.89   1.61     16.9   4.26     23.
```

```
pivot_longer(stats, everything(), names_sep = "_", names_to = c("var", ".value"))
## # A tibble: 5 x 3
##   var      mean    sd
##   <chr>   <dbl> <dbl>
## 1 displ    3.47  1.29
## 2 year  2004.    4.51
## 3 cyl      5.89  1.61
## 4 cty     16.9   4.26
## 5 hwy     23.4   5.95
```

pivot_wider

- Realiza la operación inversa a `pivot_longer` (documentación)

```
library(tidyr)
table2
## # A tibble: 12 x 4
##    country      year type
##    <chr>       <int> <chr>
##  1 Afghanistan  1999 cases
##  2 Afghanistan  1999 population   1
##  3 Afghanistan  2000 cases
##  4 Afghanistan  2000 population   2
##  5 Brazil       1999 cases
##  6 Brazil       1999 population  17
##  7 Brazil       2000 cases
##  8 Brazil       2000 population  17
##  9 China        1999 cases
## 10 China        1999 population 127
## 11 China        2000 cases
## 12 China        2000 population 128
```

```
pivot_wider(table2,
            names_from = type,
            values_from = count)
## # A tibble: 6 x 4
##   country      year  cases populati
##   <chr>       <int>  <int>      <in
## 1 Afghanistan  1999    745   199870
## 2 Afghanistan  2000   2666   205953
## 3 Brazil       1999  37737  1720063
## 4 Brazil       2000  80488  1745048
## 5 China        1999 212258 12729152
## 6 China        2000 213766 12804285
```

Ejemplos pivot_wider

- Dependiendo del uso, a veces es útil transformar nuestros datos en un formato no ordenado
- Es raro tener que usar `pivot_wider` para transformar una dataframe en datos ordenados (cada columna representa una variable)
- Se usa bastante para dos tareas:
    1. crear tablas resumen
    2. transformar datos para modelización
- Más ejemplos: vignette *pivoting*

Ejemplo tabla resumen

```
cty <-
  mpg %>%
    group_by(year, class) %>%
    summarize(avg_cty = mean(cty))

head(cty)
## # A tibble: 6 x 3
## # Groups:   year [1]
##    year class      avg_cty
##   <int> <chr>        <dbl>
## 1  1999 2seater       15.5
## 2  1999 compact       19.8
## 3  1999 midsize       18.2
## 4  1999 minivan       16.2
## 5  1999 pickup        13
## 6  1999 subcompact    21.6
```

```
pivot_wider(cty, names_from = class, values_from = avg_cty)
## # A tibble: 2 x 8
## # Groups:   year [2]
##    year `2seater` compact midsize minivan pickup subcompact   suv
##   <int>     <dbl>   <dbl>   <dbl>   <dbl>  <dbl>       <dbl> <dbl>
## 1  1999      15.5    19.8    18.2    16.2     13        21.6  13.4
## 2  2008      15.3    20.5    19.3    15.4     13        18.9  13.6
```

Ejemplo tabla resumen múltiple

```
cty <-
  mpg %>%
    group_by(year, class) %>%
    summarize(avg_cty = mean(c
              sd_cty = sd(cty)

head(cty)
## # A tibble: 6 x 4
## # Groups:   year [1]
##    year class      avg_cty
##   <int> <chr>        <dbl>
## 1  1999 2seater       15.5
## 2  1999 compact       19.8
## 3  1999 midsize       18.2
## 4  1999 minivan       16.2
## 5  1999 pickup        13
## 6  1999 subcompact    21.6
```

```
pivot_wider(cty,
            names_from = year,
            values_from = c(avg_cty, sd_cty))
## # A tibble: 7 x 5
##   class      avg_cty_1999 avg_cty_2008 sd_c
##   <chr>             <dbl>        <dbl>
## 1 2seater            15.5         15.3
## 2 compact            19.8         20.5
## 3 midsize            18.2         19.3
## 4 minivan            16.2         15.4
## 5 pickup             13           13
## 6 subcompact         21.6         18.9
## 7 suv                13.4         13.6
```

Ejemplo modelización

- En este ejemplo tenemos 6 variables: país, continente, año, esperanza de vida, población, PIB per cápita

```
gapminder
## # A tibble: 1,704 x 6
##    country     continent  year lifeExp      pop gdpPercap
##    <fct>       <fct>     <int>   <dbl>    <int>     <dbl>
##  1 Afghanistan Asia       1952    28.8  8425333      779.
##  2 Afghanistan Asia       1957    30.3  9240934      821.
##  3 Afghanistan Asia       1962    32.0 10267083      853.
##  4 Afghanistan Asia       1967    34.0 11537966      836.
##  5 Afghanistan Asia       1972    36.1 13079460      740.
##  6 Afghanistan Asia       1977    38.4 14880372      786.
##  7 Afghanistan Asia       1982    39.9 12881816      978.
##  8 Afghanistan Asia       1987    40.8 13867957      852.
##  9 Afghanistan Asia       1992    41.7 16317921      649.
## 10 Afghanistan Asia       1997    41.8 22227415      635.
## # ... with 1,694 more rows
```

- Diríamos que estos datos están ordenados, ya que cada variable se corresponde con una columna

- Este format es útil, entre otras cosas, para realizar gráficos

- Si quisiéramos, por ejemplo, realizar un modelo para predecir la esperanza de vida de China basándonos en el resto de paises de su continente, necesitamos una columna para cada país

```
gapminder %>%
  filter(continent == "Asia") %>%
  pivot_wider(id_cols = year, names_from = country, values_from = lifeExp)
## # A tibble: 12 x 34
##     year Afghanistan Bahrain Bangladesh Cambodia China `Hong Kong, Chi~ India 1
##    <int>       <dbl>   <dbl>      <dbl>    <dbl> <dbl>             <dbl> <dbl>
##  1  1952        28.8    50.9       37.5     39.4  44                61.0  37.4
##  2  1957        30.3    53.8       39.3     41.4  50.5              64.8  40.2
##  3  1962        32.0    56.9       41.2     43.4  44.5              67.6  43.6
##  4  1967        34.0    59.9       43.5     45.4  58.4              70    47.2
##  5  1972        36.1    63.3       45.3     40.3  63.1              72    50.7
##  6  1977        38.4    65.6       46.9     31.2  64.0              73.6  54.2
##  7  1982        39.9    69.1       50.0     51.0  65.5              75.4  56.6
##  8  1987        40.8    70.8       52.8     53.9  67.3              76.2  58.6
##  9  1992        41.7    72.6       56.0     55.8  68.7              77.6  60.2
## 10  1997        41.8    73.9       59.4     56.5  70.4              80    61.8
## 11  2002        42.1    74.8       62.0     56.8  72.0              81.5  62.9
## 12  2007        43.8    75.6       64.1     59.7  73.0              82.2  64.7
## # ... with 18 more variables: Kuwait <dbl>, Lebanon <dbl>, Malaysia <dbl>, Mong
## #   Philippines <dbl>, `Saudi Arabia` <dbl>, Singapore <dbl>, `Sri Lanka` <dbl>
## #   and Gaza` <dbl>, `Yemen, Rep.` <dbl>
```

separate

- Múltiples variables codificadas en una única columna

```
table3
## # A tibble: 6 x 3
##   country      year rate
## * <chr>       <int> <chr>
## 1 Afghanistan  1999 745/19987071
## 2 Afghanistan  2000 2666/20595360
## 3 Brazil       1999 37737/172006362
## 4 Brazil       2000 80488/174504898
## 5 China        1999 212258/1272915272
## 6 China        2000 213766/1280428583
```

```
separate(table3, rate, into = c("cases", "population"), sep = "/")
## # A tibble: 6 x 4
##   country      year cases  population
##   <chr>       <int> <chr>  <chr>
## 1 Afghanistan  1999 745    19987071
## 2 Afghanistan  2000 2666   20595360
## 3 Brazil       1999 37737  172006362
## 4 Brazil       2000 80488  174504898
## 5 China        1999 212258 1272915272
## 6 China        2000 213766 1280428583
```

- Por defecto `separate()` mantiene el tipo de la columna en las nuevas

```
separate(table3, rate, into = c("cases", "population"), sep = "/", convert = TRUE)
## # A tibble: 6 x 4
##   country      year  cases population
##   <chr>       <int>  <int>      <int>
## 1 Afghanistan  1999    745   19987071
## 2 Afghanistan  2000   2666   20595360
## 3 Brazil       1999  37737  172006362
## 4 Brazil       2000  80488  174504898
## 5 China        1999 212258 1272915272
## 6 China        2000 213766 1280428583
```

Ejemplo

```
separate(economics, date, into = c("year", "month", "day"), sep = "-", convert = T
## # A tibble: 574 x 8
##     year month   day   pce    pop psavert uempmed unemploy
##    <int> <int> <int> <dbl>  <dbl>   <dbl>   <dbl>    <dbl>
##  1  1967     7     1  507. 198712    12.6     4.5     2944
##  2  1967     8     1  510. 198911    12.6     4.7     2945
##  3  1967     9     1  516. 199113    11.9     4.6     2958
##  4  1967    10     1  512. 199311    12.9     4.9     3143
##  5  1967    11     1  517. 199498    12.8     4.7     3066
##  6  1967    12     1  525. 199657    11.8     4.8     3018
##  7  1968     1     1  531. 199808    11.7     5.1     2878
##  8  1968     2     1  534. 199920    12.3     4.5     3001
##  9  1968     3     1  544. 200056    11.7     4.1     2877
## 10  1968     4     1  544  200208    12.3     4.6     2709
## # ... with 564 more rows
```

unite

- Una única variable que está codificada en varias columnas

```
unite(mpg, make, manufacturer, model, sep = "_")
## # A tibble: 234 x 10
##    make             displ  year   cyl trans      drv     cty   hwy fl    class
##    <chr>            <dbl> <int> <int> <chr>      <chr> <int> <int> <chr> <chr>
##  1 audi_a4            1.8  1999     4 auto(l5)   f        18    29 p     compact
##  2 audi_a4            1.8  1999     4 manual(m5) f        21    29 p     compact
##  3 audi_a4            2    2008     4 manual(m6) f        20    31 p     compact
##  4 audi_a4            2    2008     4 auto(av)   f        21    30 p     compact
##  5 audi_a4            2.8  1999     6 auto(l5)   f        16    26 p     compact
##  6 audi_a4            2.8  1999     6 manual(m5) f        18    26 p     compact
##  7 audi_a4            3.1  2008     6 auto(av)   f        18    27 p     compact
##  8 audi_a4 quattro    1.8  1999     4 manual(m5) 4        18    26 p     compact
##  9 audi_a4 quattro    1.8  1999     4 auto(l5)   4        16    25 p     compact
## 10 audi_a4 quattro    2    2008     4 manual(m6) 4        20    28 p     compact
## # ... with 224 more rows
```

Ejemplo

```
storms %>%
  unite(date, year, month, day, sep = "-", remove = FALSE, na.rm = TRUE) %>%
  select(date, year, month, day)
## # A tibble: 10,010 x 4
##    date       year month   day
##    <chr>     <dbl> <dbl> <int>
##  1 1975-6-27  1975     6    27
##  2 1975-6-27  1975     6    27
##  3 1975-6-27  1975     6    27
##  4 1975-6-27  1975     6    27
##  5 1975-6-28  1975     6    28
##  6 1975-6-28  1975     6    28
##  7 1975-6-28  1975     6    28
##  8 1975-6-28  1975     6    28
##  9 1975-6-29  1975     6    29
## 10 1975-6-29  1975     6    29
## # ... with 10,000 more rows
```

Missing values en R

- `NA` es una constante que representa valores que faltan (*missing values*)
- Puede estar contenida dentro de vectores (columnas) de cualquier tipo
- `is.na()` devuelve `TRUE` si el valor es `NA` y `FALSE` en caso contrario
- Muchas funciones de R tienen un parámetro opcional `na.rm` que ignora `NA`s

```r
airquality %>%
  mutate(Ozone_NA = is.na(Ozone)) %>%
  select(Ozone, Ozone_NA) %>%
  slice(1:15)
##    Ozone Ozone_NA
## 1     41    FALSE
## 2     36    FALSE
## 3     12    FALSE
## 4     18    FALSE
## 5     NA     TRUE
## 6     28    FALSE
## 7     23    FALSE
## 8     19    FALSE
## 9      8    FALSE
## 10    NA     TRUE
## 11     7    FALSE
## 12    16    FALSE
## 13    11    FALSE
## 14    14    FALSE
## 15    18    FALSE
```

```r
dia <-
  diamonds %>%
    mutate(y_new = ifelse(!between(y, 3, 20), NA, y))

dia %>%
  summarize(y_na = sum(is.na(y_new)))
## # A tibble: 1 x 1
##    y_na
##   <int>
## 1     9
```

```
dia %>%
  filter(is.na(y_new)) %>%
  select(y, y_new)
## # A tibble: 9 x 2
##       y y_new
##   <dbl> <dbl>
## 1   0      NA
## 2   0      NA
## 3  58.9    NA
## 4   0      NA
## 5   0      NA
## 6   0      NA
## 7  31.8    NA
## 8   0      NA
## 9   0      NA
```

```
dia %>%
  summarize(avg = mean(y_new))
## # A tibble: 1 x 1
##     avg
##   <dbl>
## 1    NA
```

```
dia %>%
  summarize(avg = mean(y_new,
                       na.rm = TRUE))
## # A tibble: 1 x 1
##     avg
##   <dbl>
## 1  5.73
```

Funciones para gestionar NA

tidyr también tiene otras funciones útiles para trabajar con `NA`s:

- `drop_na()`, elimina filas que tengan algún `NA`
- `fill()`, completa `NA`s con el valor anterior
- `replace_na()`, reemplaza `NA`s por un valor

drop_na

```
str(airquality)
## 'data.frame':    153 obs. of  6 variables:
##  $ Ozone  : int  41 36 12 18 NA 28 23 19 8 NA ...
##  $ Solar.R: int  190 118 149 313 NA NA 299 99 19 194 ...
##  $ Wind   : num  7.4 8 12.6 11.5 14.3 14.9 8.6 13.8 20.1 8.6 ...
##  $ Temp   : int  67 72 74 62 56 66 65 59 61 69 ...
##  $ Month  : int  5 5 5 5 5 5 5 5 5 5 ...
##  $ Day    : int  1 2 3 4 5 6 7 8 9 10 ...
```

```
summary(airquality)
##      Ozone           Solar.R           Wind             Temp           Month
##  Min.   :  1.00   Min.   :  7.0   Min.   : 1.700   Min.   :56.00   Min.   :5.00
##  1st Qu.: 18.00   1st Qu.:115.8   1st Qu.: 7.400   1st Qu.:72.00   1st Qu.:6.00
##  Median : 31.50   Median :205.0   Median : 9.700   Median :79.00   Median :7.00
##  Mean   : 42.13   Mean   :185.9   Mean   : 9.958   Mean   :77.88   Mean   :6.99
##  3rd Qu.: 63.25   3rd Qu.:258.8   3rd Qu.:11.500   3rd Qu.:85.00   3rd Qu.:8.00
##  Max.   :168.00   Max.   :334.0   Max.   :20.700   Max.   :97.00   Max.   :9.00
##  NA's   :37       NA's   :7
```

```
airquality %>%
  drop_na() %>%
  str()
## 'data.frame':    111 obs. of  6 variables:
##  $ Ozone  : int  41 36 12 18 23 19 8 16 11 14 ...
##  $ Solar.R: int  190 118 149 313 299 99 19 256 290 274 ...
##  $ Wind   : num  7.4 8 12.6 11.5 8.6 13.8 20.1 9.7 9.2 10.9 ...
##  $ Temp   : int  67 72 74 62 65 59 61 69 66 68 ...
##  $ Month  : int  5 5 5 5 5 5 5 5 5 5 ...
##  $ Day    : int  1 2 3 4 7 8 9 12 13 14 ...
```

```
filter(airquality, is.na(Ozone), is.na(Solar.R))
##   Ozone Solar.R Wind Temp Month Day
## 1    NA      NA 14.3   56     5   5
## 2    NA      NA  8.0   57     5  27
```

```
airquality %>%
  drop_na(Ozone) %>%
  str()
## 'data.frame':    116 obs. of  6 variables:
##  $ Ozone  : int  41 36 12 18 28 23 19 8 7 16 ...
##  $ Solar.R: int  190 118 149 313 NA 299 99 19 NA 256 ...
##  $ Wind   : num  7.4 8 12.6 11.5 14.9 8.6 13.8 20.1 6.9 9.7 ...
##  $ Temp   : int  67 72 74 62 66 65 59 61 74 69 ...
##  $ Month  : int  5 5 5 5 5 5 5 5 5 5 ...
##  $ Day    : int  1 2 3 4 6 7 8 9 11 12 ...
```

fill

```
airquality %>%
  # no fill
  slice(c(1:10, 50:59)) %>%
  select(-c(Temp, Wind))
##    Ozone Solar.R Month Day
## 1     41     190     5   1
## 2     36     118     5   2
## 3     12     149     5   3
## 4     18     313     5   4
## 5     NA      NA     5   5
## 6     28      NA     5   6
## 7     23     299     5   7
## 8     19      99     5   8
## 9      8      19     5   9
## 10    NA     194     5  10
## 11    12     120     6  19
## 12    13     137     6  20
## 13    NA     150     6  21
## 14    NA      59     6  22
## 15    NA      91     6  23
## 16    NA     250     6  24
## 17    NA     135     6  25
## 18    NA     127     6  26
## 19    NA      47     6  27
## 20    NA      98     6  28
```

```
airquality %>%
  fill(Ozone, .direction = "down") %>%
  slice(c(1:10, 50:59)) %>%
  select(-c(Temp, Wind))
##    Ozone Solar.R Month Day
## 1     41     190     5   1
## 2     36     118     5   2
## 3     12     149     5   3
## 4     18     313     5   4
## 5     18      NA     5   5
## 6     28      NA     5   6
## 7     23     299     5   7
## 8     19      99     5   8
## 9      8      19     5   9
## 10     8     194     5  10
## 11    12     120     6  19
## 12    13     137     6  20
## 13    13     150     6  21
## 14    13      59     6  22
## 15    13      91     6  23
## 16    13     250     6  24
## 17    13     135     6  25
## 18    13     127     6  26
## 19    13      47     6  27
## 20    13      98     6  28
```

replace_na

```
airquality %>%
  mutate(O3_noNA = replace_na(Ozone, mean(Ozone, na.rm = T)), .after = Ozone) %>%
  slice(c(1:10, 50:55)) %>%
  select(-c(Wind, Temp, Solar.R))
##    Ozone  O3_noNA Month Day
## 1     41 41.00000     5   1
## 2     36 36.00000     5   2
## 3     12 12.00000     5   3
## 4     18 18.00000     5   4
## 5     NA 42.12931     5   5
## 6     28 28.00000     5   6
## 7     23 23.00000     5   7
## 8     19 19.00000     5   8
## 9      8  8.00000     5   9
## 10    NA 42.12931     5  10
## 11    12 12.00000     6  19
## 12    13 13.00000     6  20
## 13    NA 42.12931     6  21
## 14    NA 42.12931     6  22
## 15    NA 42.12931     6  23
## 16    NA 42.12931     6  24
```